Міністерство освіти і науки України
Національний технічний університет України
"Київський політехнічний інститут імені Ігоря Сікорського"
Фізико-технічний інститут

КРИПТОГРАФІЯ

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

«Експериментальна оцінка ентропії на символ джерела відкритого тексту»

Виконали студенти групи ФБ-43 Вориняк Василь та Оніщук Максим

Перевірила: Селюх Поліна Валентинівна

Київ - 2026

Мета: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

1. Підготовка тексту

Ми обрали роман Ф. М. Достоєвського «Бесы» (три частини та глава «У Тихона»).

Алфавіт: 32 літери (ё замінено на е) і пробіл, разом 33 символи.

Правила обробки:

1. Усі літери переводяться в нижній регістр, ё замінюється на е.
2. Знаки наголосу та м'які переноси видаляються, щоб не розривати слова.
3. Усі символи поза алфавітом замінюються пробілом, послідовності пробілів зводяться до одного.
4. Для тексту без пробілів з нормалізованого тексту вилучаються всі пробіли.

Для кожного пункту написано окремий скрипт на Python.

step1_prepare.py:

```
import re

text = open("besy.txt", encoding="utf-8").read().lower()
text = text.replace("ё", "е").replace(chr(0x301), "")
text = re.sub("[^абвгдежзийклмнопрстуфхцчшщъыьэюя]+", " ", text).strip()

open("text_spaces.txt", "w", encoding="utf-8").write(text)
open("text_nospaces.txt", "w", encoding="utf-8").write(text.replace(" ",
""))

print("з пробілами:", len(text))
print("без пробілів:", len(text.replace(" ", "")))
print("символів в алфавіті:", len(set(text)))
```

Результат:

```
з пробілами: 1241313
без пробілів: 1033756
символів в алфавіті: 33
```

2. Розрахунок статистичних характеристик тексту

H_1 обчислюється за частотами окремих символів: $H_1 = -\Sigma\, p_i \cdot \log_2 p_i$. H_2 обчислюється за частотами біграм: $H_2 = H(x_1x_2) / 2$. Біграми з перетином беруться зі зсувом на 1 символ, без перетину - зі зсувом на 2.

step2_frequencies.py:

```
import math
from collections import Counter


def entropy(c):
    n = sum(c.values())
    return sum(-k / n * math.log2(k / n) for k in c.values())


def bigrams(t, step):
    return Counter(a + b for a, b in zip(t[::step], t[1::step]))


for name in ("text_spaces.txt", "text_nospaces.txt"):
    t = open(name, encoding="utf-8").read()
    c = Counter(t)
    print(name)
    for s, k in c.most_common():
        print(f"  {s!r} {k} {k / len(t):.5f}")
    print(f"H0 = {math.log2(len(c)):.4f}")
    print(f"H1 = {entropy(c):.4f}")
    for step, kind in ((1, "з перетином"), (2, "без перетину")):
        b = bigrams(t, step)
        n = sum(b.values())
        print(f"{kind}: {n} біграм, топ-5:", ", ".join(f"{p!r} {k /
n:.5f}" for p, k in b.most_common(5)))
        print(f"H2 = {entropy(b) / 2:.4f}")

b = bigrams(open("text_spaces.txt", encoding="utf-8").read(), 1)
abc = sorted({p[0] for p in b})
with open("bigrams.csv", "w", encoding="utf-8") as f:
    f.write(";" + ";".join(abc) + "\n")
    for x in abc:
        f.write(x + ";" + ";".join(str(b[x + y]) for y in abc) + "\n")
print("жы, шы, чя:", b["жы"], b["шы"], b["чя"])
```

2.1. Частоти символів

Ліворуч текст з пробілами (пробіл позначено _), праворуч без пробілів.

№	Символ	Кількість	Частота	Символ	Кількість	Частота
1	_	207 557	0.16721	о	117 534	0.11370
2	о	117 534	0.09469	е	92 034	0.08903
3	е	92 034	0.07414	а	81 458	0.07880
4	а	81 458	0.06562	и	68 950	0.06670
5	и	68 950	0.05555	н	67 813	0.06560
6	н	67 813	0.05463	т	65 824	0.06367

№	Символ	Кількість	Частота	Символ	Кількість	Частота
7	т	65 824	0.05303	с	55 424	0.05361
8	с	55 424	0.04465	в	52 235	0.05053
9	в	52 235	0.04208	л	47 665	0.04611
10	л	47 665	0.03840	р	43 289	0.04188
11	р	43 289	0.03487	м	33 108	0.03203
12	м	33 108	0.02667	к	32 188	0.03114
13	к	32 188	0.02593	д	30 738	0.02973
14	д	30 738	0.02476	п	29 148	0.02820
15	п	29 148	0.02348	у	28 634	0.02770
16	у	28 634	0.02307	я	21 876	0.02116
17	я	21 876	0.01762	ь	20 211	0.01955
18	ь	20 211	0.01628	ч	18 901	0.01828
19	ч	18 901	0.01523	г	18 481	0.01788
20	г	18 481	0.01489	ы	17 984	0.01740
21	ы	17 984	0.01449	б	17 445	0.01688
22	б	17 445	0.01405	з	16 443	0.01591
23	з	16 443	0.01325	ж	11 202	0.01084
24	ж	11 202	0.00902	й	10 585	0.01024
25	й	10 585	0.00853	ш	8 905	0.00861
26	ш	8 905	0.00717	х	8 240	0.00797
27	х	8 240	0.00664	ю	6 498	0.00629
28	ю	6 498	0.00523	э	3 065	0.00296
29	э	3 065	0.00247	ц	2 995	0.00290
30	ц	2 995	0.00241	щ	2 873	0.00278
31	щ	2 873	0.00231	ф	1 703	0.00165
32	ф	1 703	0.00137	ъ	307	0.00030
33	ъ	307	0.00025			

2.2. П'ять найчастіших біграм

№	з пробілами, з перетином		з пробілами, без перетину	
1	о_	0.02399	о_	0.02414
2	е_	0.01986	е_	0.01971
3	_в	0.01846	_в	0.01848
4	_н	0.01718	_н	0.01722

№	з пробілами, з перетином		з пробілами, без перетину	
5	и_	0.01699	и_	0.01713

№	без пробілів, з перетином		без пробілів, без перетину	
1	то	0.01692	то	0.01702
2	ов	0.01359	ов	0.01374
3	ст	0.01322	ст	0.01323
4	но	0.01295	но	0.01284
5	не	0.01273	не	0.01266

Повна таблиця частот біграм у файлі bigrams.csv

2.3. Ентропія

Текст	$H_0 = \log_2 m$	H_1	H_2 з перетином	H_2 без перетину
з пробілами (m = 33)	5.0444	4.3545	3.9480	3.9479
без пробілів (m = 32)	5.0000	4.4467	4.1293	4.1295

Відповіді до пункту 2

H_2 для біграм з перетином і без перетину майже однакові. Різниця становить 0.00006 біт для тексту з пробілами і 0.00012 біт без пробілів, тобто тисячні частки відсотка. Обидва способи оцінюють той самий розподіл біграм. Невелика різниця виникає через різний обсяг вибірки та випадкові коливання частот рідкісних біграм.

Більше статистичних даних використовує спосіб з перетином: 1 241 312 біграм проти 620 656 без перетину.

Без пробілів ентропія зростає: H_1 з 4.3545 до 4.4467, H_2 з 3.9480 до 4.1293. Пробіл - найчастіший (16.7 %) і добре передбачуваний символ. Без нього розподіл літер стає рівномірнішим, а закономірності на межах слів зникають.

3. Дослідження впливу розподілу символів на ентропію

Послідовності по 200 000 символів:

- А - перші 200 000 символів роману;
- Б - повторення літери «о»;

- В - випадкові рівноймовірні символи того самого алфавіту.

Прогноз: H_1(Б) < H_1(А) < H_1(В). У Б невизначеності немає (H_1 = 0), у В вона максимальна (H_1 ≈ $\log_2 33$ = 5.04). Природний текст буде між ними, бо літери в ньому нерівноймовірні.

step3_distribution.py:

```
import math
import random
from collections import Counter


def entropy(t):
    return sum(-k / len(t) * math.log2(k / len(t)) for k in
Counter(t).values())


random.seed(1872)
t = open("text_spaces.txt", encoding="utf-8").read()
N = 200000
a = t[:N]
b = "о" * N
v = "".join(random.choices(sorted(set(t)), k=N))

print(f"H0 = {math.log2(len(set(t))):.4f}")
for name, s in (("А", a), ("Б", b), ("В", v)):
    print(f"{name}: H1 = {entropy(s):.4f}")
```

Послідовність	**H_1**
А	4.3534
Б	0.0000
В	5.0443

Прогноз підтвердився. Що рівномірніший розподіл імовірностей символів, то більша ентропія: вироджений розподіл дає 0, рівноймовірний — максимум $\log_2 m$. Значення для В трохи менше за $\log_2 33$ через скінченну довжину послідовності.

4. Дослідження залежностей між символами

Д - періодична послідовність «бесыбесы…» довжиною 120 000 символів. Г - ті самі символи у випадковому порядку, тому частоти символів однакові. Додатково взято пару з непарним періодом: Д′ = «бесовбесов…» і її перестановку Г′.

Прогноз:

1. H_1 для Г і Д однакові, бо однакові частоти символів.
2. H_2 суттєво відрізнятимуться.

3. Менше H_2 буде в Д, бо там кожен символ однозначно визначає наступний.
4. Для Г H_2 з перетином і без перетину однакові. Для Д — ні: без перетину біграми бачать лише пари «бе» і «сы», тому H_2 буде менше.

step4_dependencies.py:

```
import math
import random
from collections import Counter


def entropy(c):
    n = sum(c.values())
    return sum(-k / n * math.log2(k / n) for k in c.values())


def bigrams(t, step):
    return Counter(a + b for a, b in zip(t[::step], t[1::step]))


random.seed(1872)
for block in ("бесы", "бесов"):
    d = block * (120000 // len(block))
    g = "".join(random.sample(d, len(d)))
    for name, s in (("Г", g), ("Д", d)):
        h1 = entropy(Counter(s))
        print(f"{name} ({block}): H1 = {h1:.4f}, H2 = {entropy(bigrams(s,
1)) / 2:.4f} / {entropy(bigrams(s, 2)) / 2:.4f}")
```

	H_1	H_2 з перетином	H_2 без перетину
Г	2.0000	2.0000	2.0000
Д	2.0000	1.0000	0.5000
Г′	2.3219	2.3219	2.3218
Д′	2.3219	1.1610	1.1610

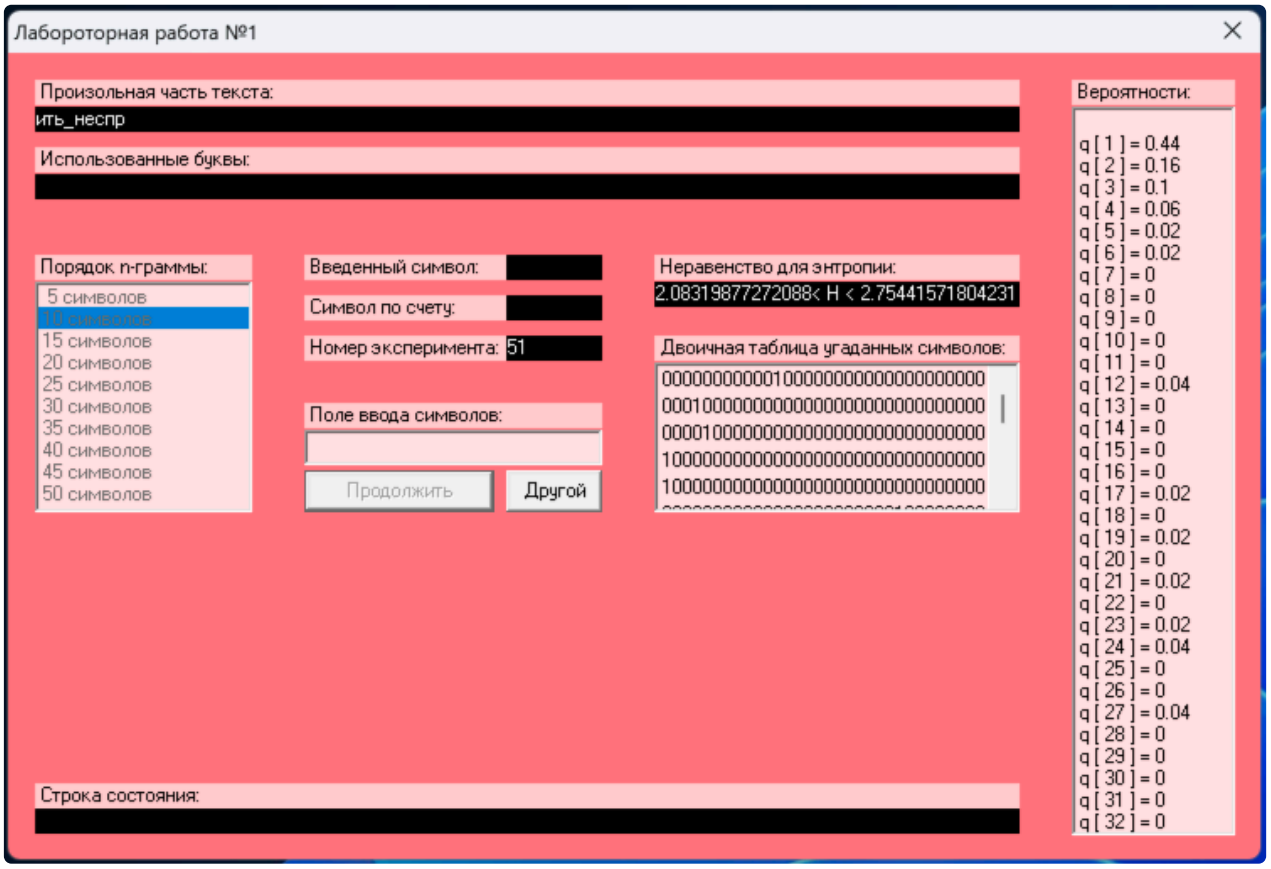
Прогноз підтвердився:

- H_1 залежить лише від частот окремих символів, а не від їхнього порядку, тому для Г і Д вона однакова.
- H_2 враховує, які символи стоять поруч. У Д трапляються лише 4 пари з 16 можливих, тому H_2 удвічі менша. Різниця між способами підрахунку для Д виникає через парний період; у Д′ з непарним періодом її немає.
- Модель біграм враховує залежність символу від попереднього, якої модель незалежних символів не бачить: для неї Г і Д нерозрізненні.

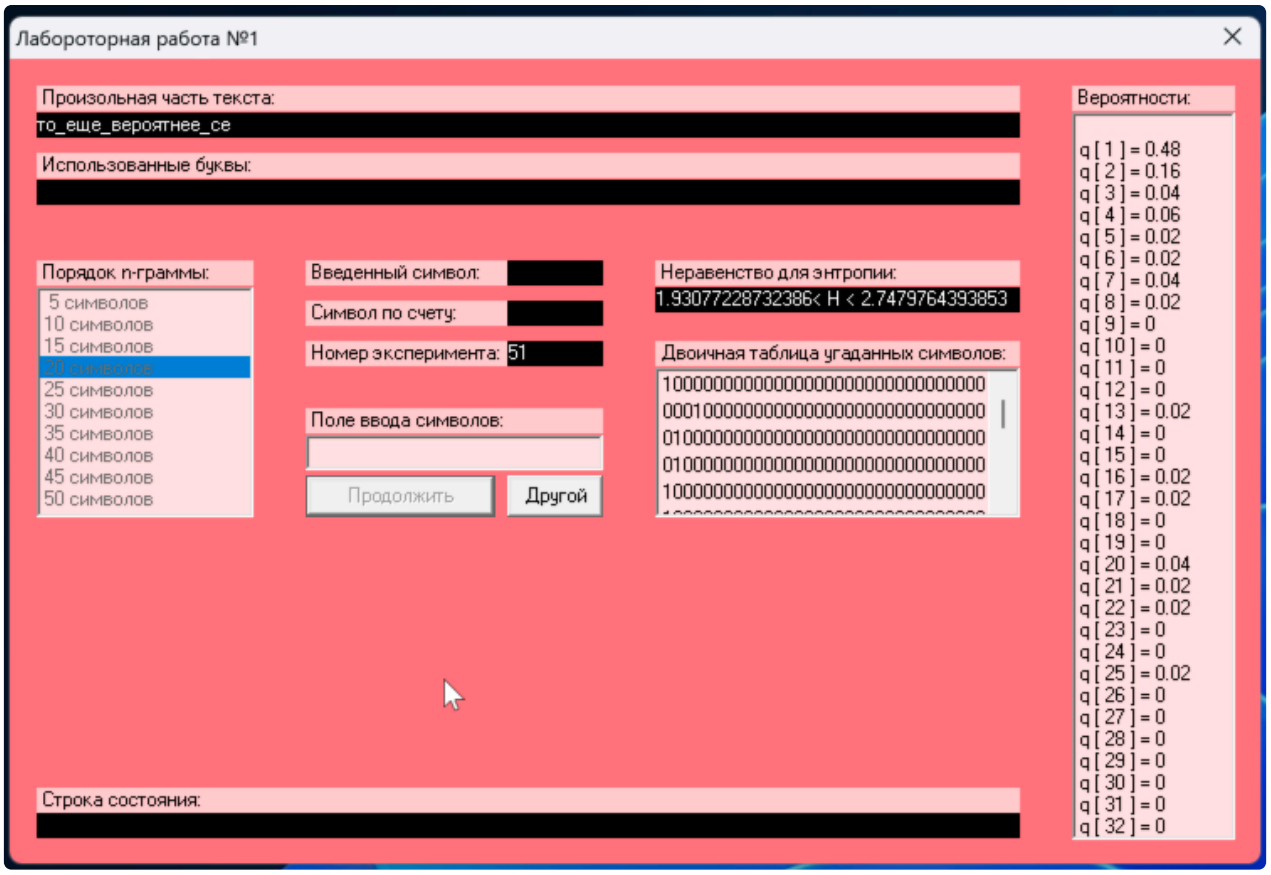
5. Експериментальна оцінка ентропії джерела

За допомогою CoolPinkProgram оцінено $H^{(10)}$, $H^{(20)}$, $H^{(30)}$, по 50 експериментів для кожного значення. Програма показує n − 1 символ тексту, експериментатор вгадує наступний. За частками вгадувань з першої, другої і т. д. спроби програма обчислює нижню й верхню межі ентропії. Вгадування відбувається на вбудованому в програму тексті, фрагменті російського перекладу книги К. С. Льюїса «Просто християнство». Алфавіт цього тексту 32 символи (31 літера без ё та ъ і пробіл), тому для нього $H_0 = \log_2 32 = 5$.

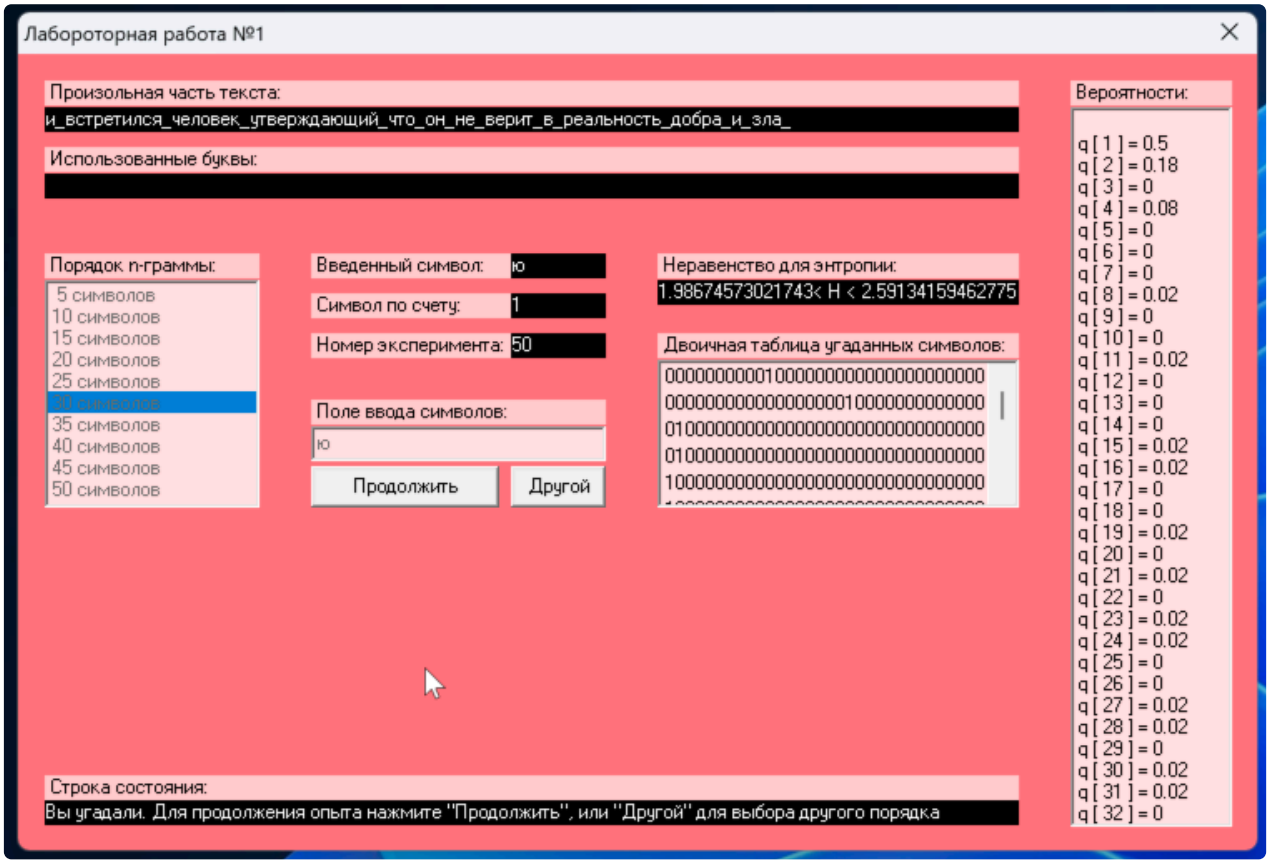
$H^{(10)}$: 2.0832 < H < 2.7544



$H^{(20)}$: 1.9308 < H < 2.7480



$H^{(30)}$: 1.9867 < H < 2.5913



Оцінка	Отримане значення
H_1	4.3545
H_2	3.9480
$H^{(10)}$	2.0832 – 2.7544
$H^{(20)}$	1.9308 – 2.7480

Оцінка	Отримане значення
$H^{(30)}$	1.9867 – 2.5913

Відповіді до пункту 5

1. Оцінки не повинні збігатися, бо описують різні моделі джерела: H_1 - незалежні символи, H_2 - пари символів, $H^{(n)}$ - символ за відомих n - 1 попередніх. Крім того, $H^{(n)}$ отримано як інтервал з невеликої кількості людських спроб і на іншому тексті вбудованому в програму.
2. H_1 враховує лише частоти окремих символів. H_2 ще й залежність між двома сусідніми символами: наприклад, «жы», «шы», «чя» у тексті не трапляються жодного разу.
3. Довший контекст дозволяє використати будову слів, граматику і зміст, тому наступний символ легше вгадати і невизначеність менша.
4. Оцінки зменшуються зі збільшенням контексту: H_1 = 4.35, H_2 = 3.95, $H^{(10)}$ = 2.08-2.75, $H^{(20)}$ = 1.93-2.75, $H^{(30)}$ = 1.99-2.59. Найбільше падіння між H_2 і $H^{(10)}$. Далі верхня межа спадає повільно, а частка вгадувань з першої спроби зростає: 0.44, 0.48, 0.50. Інтервали для 10, 20 і 30 символів перекриваються, тож при 50 експериментах різниця між ними лежить у межах похибки.

6. Оцінювання надлишковості джерела

$R = 1 - H / H_0$. Тут $H_0 = \log_2 33 \approx 5.0444$ для тексту з пробілами і $H_0 = \log_2 32 = 5$ для тексту без пробілів та для CoolPinkProgram. Межі, отримані в CoolPinkProgram, вписуються у словник coolpink.

step6_redundancy.py:

```
import bz2
import math
from collections import Counter


def entropy(c):
    n = sum(c.values())
    return sum(-k / n * math.log2(k / n) for k in c.values())


for name in ("text_spaces.txt", "text_nospaces.txt"):
    t = open(name, encoding="utf-8").read()
    h0 = math.log2(len(set(t)))
    h1 = entropy(Counter(t))
    h2 = entropy(Counter(a + b for a, b in zip(t, t[1:]))) / 2
    bz = 8 * len(bz2.compress(t.encode("cp1251"))) / len(t)
    print(f"{name}: R(H1) = {1 - h1 / h0:.2%}, R(H2) = {1 - h2 / h0:.2%},
bz2 = {bz:.4f} біт/символ, R = {1 - bz / h0:.2%}")

coolpink = {10: (2.08319877272088, 2.75441571804231), 20:
(1.93077228732386, 2.7479764393853), 30: (1.98674573021743,
```

```
2.59134159462775)}
for n, (low, high) in coolpink.items():
    print(f"H({n}): R = {1 - high / 5:.2%} ... {1 - low / 5:.2%}")
```

Модель	З пробілами	Без пробілів
H_1	13.68 %	11.07 %
H_2 з перетином	21.74 %	17.41 %
H_2 без перетину	21.74 %	17.41 %

Для CoolPinkProgram ентропію отримано як інтервал, тому й надлишковість — інтервал:

Модель	R
$H^{(10)}$	44.91 – 58.34 %
$H^{(20)}$	45.04 – 61.38 %
$H^{(30)}$	48.17 – 60.27 %

Для порівняння: архіватор bz2 стискає наш текст до 2.33 біт на символ, тобто надлишковість не менша за 53.8 %.

Відповіді до пункту 6

- Надлишковість зростає при врахуванні залежностей: 13.68 % за H_1, 21.74 % за H_2 і 48.17–60.27 % за $H^{(30)}$. Кожна наступна модель враховує більше закономірностей мови, тому її оцінка ентропії менша.
- Природна мова має ненульову надлишковість, бо літери нерівноймовірні й залежать одна від одної: правопис, будова слів і граматика обмежують можливі продовження тексту. Завдяки цьому мова стійка до помилок.
- Що краще можна передбачити наступний символ, то менша ентропія і тим більша надлишковість.

7. Аналіз результатів

1. Природний текст має меншу ентропію, бо його символи нерівноймовірні та залежні. У п. 3 H_1 фрагмента тексту - 4.35 біт, а випадкової рівноймовірної послідовності - 5.04 біт.
2. H_2 враховує залежність між сусідніми символами: які пари трапляються часто, а які неможливі (жы, шы, чя). H_1 враховує лише частоти окремих символів.
3. Так. Послідовності Г і Д з п. 4 мають однакове H_1 = 2.0000, але H_2 = 2.0000 для Г і 1.0000 для Д.
4. Без пробілів ентропія зросла: H_1 з 4.3545 до 4.4467, H_2 з 3.9480 до 4.1293. Пробіл найчастіший і найпередбачуваніший символ. Без нього розподіл літер рівномірніший, а закономірності на межах слів зникають.

5. Через різний обсяг вибірки (N − 1 і N/2 біграм) і випадкові коливання частот. Для нашого тексту різниця лише 0.00006–0.00012 біт. Для періодичного тексту з парним періодом вона може бути великою: для Д 1.0 проти 0.5.
6. Вони враховують контекст різної довжини: H_1 - жодного, H_2 - один сусідній символ, $H^{(n)}$: n − 1 попередніх. Що довший контекст, то менша невизначеність. До того ж $H^{(n)}$ отримано експериментально і як інтервал.
7. Експеримент з п. 4: за однакових частот символів H_1 однакові, а H_2 відрізняються вдвічі. Різницю дає лише порядок символів.
8. Ентропія це мінімальна середня кількість біт на символ при стисненні без втрат. Рівномірний код потребує $\log_2 33 \approx 5.04$ біт на символ, а оцінки ентропії значно менші, тому текст можна стиснути. bz2 стискає його до 2.33 біт на символ.

Висновки

У роботі досліджено ентропію та надлишковість російського тексту на прикладі роману Ф. М. Достоєвського «Бесы».

Модель незалежних символів дала $H_1 = 4.3545$ біт, модель біграм - $H_2 = 3.9480$ біт. Метод вгадування з довгим контекстом дав ще менші значення: $H^{(30)} = 1.99–2.59$ біт. Отже, що більше залежностей між символами враховує модель, то менша оцінка ентропії і тим більша оцінка надлишковості: від 13.68 % за H_1 до 48–60 % за $H^{(30)}$.

Експерименти з послідовностями показали, що H_1 залежить лише від розподілу символів, а H_2 - ще й від їхнього порядку. Біграми з перетином і без перетину дають практично однакові H_2 для природного тексту, але спосіб з перетином використовує вдвічі більше даних.

Висока надлишковість природної мови дозволяє стискати текст без втрат і водночас робить відкритий текст вразливим до статистичного криптоаналізу.