Протокол виконання лабораторної роботи №1

з криптографії

Виконали студенти 3 курсу, НН ФТІ, ФБ-43

Закусило Дмитрій, Топчій Микита

Варіант 6

КРИПТОГРАФІЯ

КОМП’ЮТЕРНИЙ ПРАКТИКУМ №1

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

1. Підготовка тексту

Оберіть довільний текст російською мовою обсягом не менше 1 МБ.

Виконайте попередню обробку тексту відповідно до таких правил:

●усі літери привести до нижнього регістру;

●символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;

●послідовності пробілів та інших розділових символів трактувати як один пробіл;

●для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту.

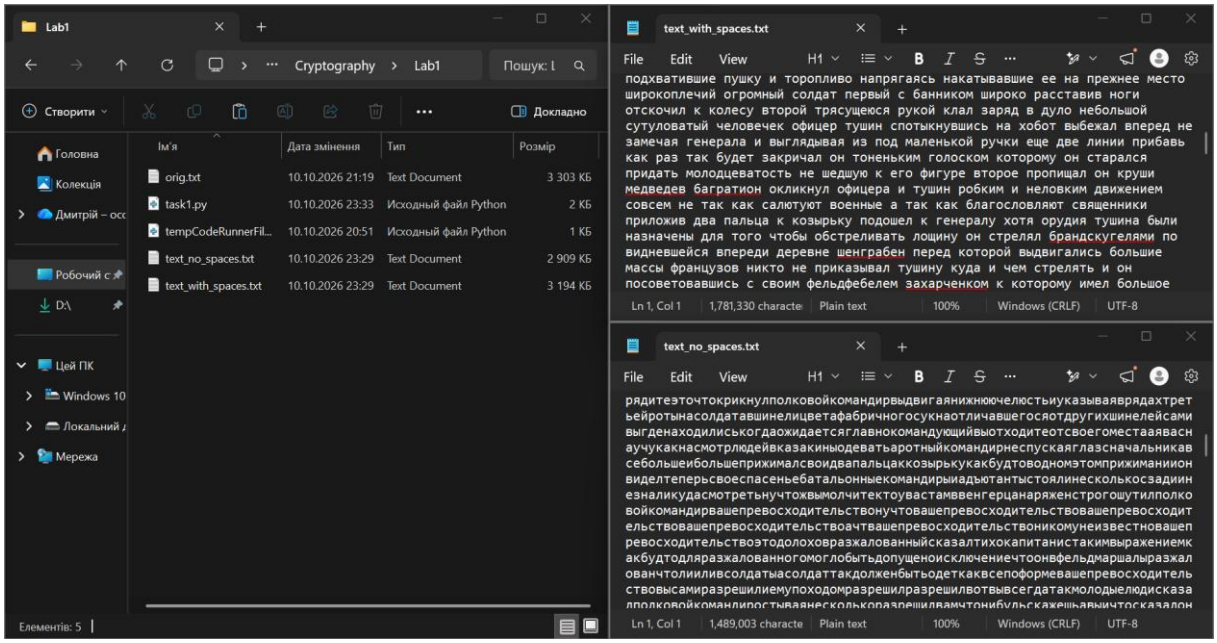
Зафіксуйте правила попередньої обробки, використані у вашій програмі.

Завантажили текст в FB2 форматі, онлайн конвертували в txt. Написали програму task1.py, яка виконує попередню обробку файлу.

Пояснення коду програми task1.py та демонстрація роботи:

Програма читає вхідний текстовий файл, переводить його в нижній регістр, замінює всі символи, крім 33 літер російського алфавіту, на пробіли, заміняє серії пробілів в один і прибирає пробіли по краях. Результат зберігається у два файли: text_with_spaces.txt і text_no_spaces.txt.

В результаті отримали дві потрібні версії тексту, відформатовані правильно:



2. Розрахунок статистичних характеристик тексту

Реалізуйте програму для:

1. підрахунку частот окремих символів;

2. підрахунку частот біграм;

3. обчислення H1 за частотами окремих символів;

4. обчислення H2 за частотами біграм.

Частоти біграм та відповідне значення H2 визначте двома способами:

●для біграм, що перетинаються, тобто при послідовному зміщенні на один символ;

● для біграм, що не перетинаються, тобто при зміщенні на два символи.

Виконайте обчислення для:

● нормалізованого тексту з пробілом як символом алфавіту;

● того самого тексту після вилучення всіх пробілів.

Для кожного випадку визначте п’ять символів та п’ять біграм із найбільшими частотами. Порівняйте значення H2, отримані для біграм, що перетинаються та не перетинаються. Поясніть можливі відмінності між результатами та визначте, який спосіб використовує більше статистичних даних.

Пояснення коду програми task2.py:

Головні у програмі - чотири функції.

char_frequencies за один прохід по тексту будує лічильник Counter(text) - словник "символ, кількість входжень" - і перетворює кількості на частоти діленням на загальну довжину тексту, що є оцінкою ймовірностей p(i).

bigram_frequencies(text, step) робить те саме, але лічильник будується по зрізах text[i:i+2] - парах сусідніх символів; параметр step визначає нарізку: step=1 бере всі пари підряд, тобто дає перетинні біграми, step=2 перескакує через символ, тобто дає неперетинні, а сумарна кількість зібраних біграм слугує знаменником для частот.

h1 - пряме обчислення формули H=-sum(p*log2(p)) по списку частот символів, результат у бітах.

h2 - та сама сума, але по частотах біграм із діленням на 2, яке переводить "біти на біграму" у "біти на символ", щоб H2 можна було порівнювати з H2.

Решта коду - читання файлів, друкування таблиць через most_common() і два виклики звіту для тексту з пробілами та без по суті використовують ці чотири функції для безпосереднього обрахунку потрібних значень та їх виводу в термінал.

Демонстрація роботи програми:

```
PS C:\Users\user\Desktop\Cryptography\Lab1> python -u
"c:\Users\user\Desktop\Cryptography\Lab1\task2.py"
TEXT WITH SPACES (text_with_spaces.txt)
H1 = 4.3778
H2 overlapping bigrams = 3.9677
H2 non-overlapping bigrams = 3.9671
top 5 characters (34 distinct):
  space: count=292327, freq=0.16411
  о: count=170329, freq=0.09562
  е: count=122690, freq=0.06888
  а: count=122595, freq=0.06882
  и: count=98715, freq=0.05542
top 5 bigrams overlapping (812 distinct):
  о : count=39498, freq=0.02217
  и : count=33420, freq=0.01876
  е : count=30333, freq=0.01703
  а : count=29067, freq=0.01632
   н: count=27895, freq=0.01566
top 5 bigrams non-overlapping (786 distinct):
  о : count=19707, freq=0.02213
  и : count=16815, freq=0.01888
  е : count=15246, freq=0.01712
  а : count=14444, freq=0.01622
   н: count=14006, freq=0.01573

TEXT WITHOUT SPACES (text_no_spaces.txt)
H1 = 4.4668
H2 overlapping bigrams = 4.1474
H2 non-overlapping bigrams = 4.1467
top 5 characters (33 distinct):
  о: count=170329, freq=0.11439
  е: count=122690, freq=0.08240
  а: count=122595, freq=0.08233
  и: count=98715, freq=0.06630
```

```
  н: count=97833, freq=0.06570
top 5 bigrams overlapping (911 distinct):
  то: count=25174, freq=0.01691
  ст: count=19637, freq=0.01319
  на: count=18216, freq=0.01223
  ов: count=17221, freq=0.01157
  ал: count=16264, freq=0.01092
top 5 bigrams non-overlapping (877 distinct):
  то: count=12525, freq=0.01682
  ст: count=9831, freq=0.01320
  на: count=9021, freq=0.01212
  ов: count=8584, freq=0.01153
  ал: count=8198, freq=0.01101
```

Аналіз результатів виводу програми

Запустивши програму, отримали результати, варто наголосити на кількох моментах:

Значення H2, обчислені для біграм, що перетинаються, та біграм, що не перетинаються, практично збігаються: 3.9677 проти 3.9671 біт/символ для тексту з пробілами та 4.1474 проти 4.1467 для тексту без пробілів. Це пояснюється тим, що обидва способи дають оцінку одного й того самого розподілу ймовірностей біграм, а на великому обсязі тексту статистичний шум від різної кількості спостережень є порівняно малим. Більше статистичних даних використовує спосіб біграм, що перетинаються: при зміщенні на один символ текст довжини N дає N−1 біграм, тоді як при зміщенні на два символи - лише близько N/2 (у нашому випадку 39 498 входжень топової біграми проти 19 707), тому саме перший спосіб є статистично точнішим.

Якщо аналізувати результати загалом, то отримані значення відповідають теоретичним: H0 > H1 > H2 для обох варіантів тексту. H1 для тексту без пробілів вища, оскільки видалення найчастішого символу (пробіл, 16.4%) вирівнює розподіл частот. Топ-5 символів (о, е, а, и, н) та топ-5 біграм (то, ст, на, ов, ал) відповідають відомим статистичним характеристикам російської мови, а для тексту з пробілами серед топових біграм переважають пари «літера-пробіл», що демонструє роль пробілу як межі слів.

3. Дослідження впливу розподілу символів на ентропію

Підготуйте три послідовності достатньої для проведення експерименту довжини:

● А - фрагмент природного російськомовного тексту;

● Б - послідовність, утворену повторенням одного символу;

● В - випадкову послідовність символів того самого алфавіту, в якій усі символи генеруються з однаковою ймовірністю.

До виконання обчислень розташуйте послідовності А, Б і В у порядку очікуваного зростання H1 та коротко обґрунтуйте свій прогноз.

За допомогою власної програми обчисліть H1 для кожної послідовності.

Порівняйте отримані результати з попереднім прогнозом. Поясніть, як характер розподілу ймовірностей символів впливає на ентропію джерела.

Припущення про взаємне розташування послідовностей: Б<А<В, адже у випадку Б у нас один символ на вибір, ентропії нема,H1=0. У варіанті А ми маємо нерівномірні частоти для символів тексту, які не є повністю випадковими, а тому значення H1 в цьому випадку буде знаходитись між нулем та максимумом. Випадок В містить в собі повністю вирівняні частоти (бо випадковим є генератор) символів, а тому ентропія в ньому буде найбільша серед усіх варіантів, близька до максимально можливої log2(34)=5.087

Пояснення коду програми task3.py

Програма формує три послідовності однакової довжини по 100 000 символів на одному алфавіті та обчислює H1 для кожної, перевикористовуючи функції char_frequencies та h1 з task2. Алфавіт береться як множина фактичних символів нормалізованого тексту (set(text), 34 символи з пробілом). Послідовність А - перші 100 тисяч символів природного тексту (зріз text[:LENGTH]); послідовність Б - повторення одного символу LENGTH разів, послідовність В - 100 тисяч випадкових виборів символу алфавіту через random.choice, що дає рівномірний розподіл.

Для кожної послідовності програма друкує H1, кількість різних символів та довжину - за цими трьома числами і перевіряється виконаний перед цим прогноз.

Демонстрація роботи програми

PS C:\Users\user\Desktop\Cryptography\Lab1> python -u "c:\Users\user\Desktop\Cryptography\Lab1\task3.py"

A natural text fragment: H1 = 4.3798, distinct chars = 34, length = 100000

B repeated single char: H1 = -0.0000, distinct chars = 1, length = 100000

C random uniform: H1 = 5.0873, distinct chars = 34, length = 100000

Аналіз отриманих результатів:

Обчислення підтвердили прогноз: отримані значення показують, що ентропія джерела визначається характером розподілу ймовірностей символів: чим «рівномірніший» розподіл, тим вища невизначеність на символ."

4. Дослідження залежностей між символами

Сформуйте дві послідовності однакової довжини, побудовані на однаковому алфавіті та з однаковими або максимально близькими частотами окремих символів:

● Г - символи розташовані у випадковому порядку;

● Д - символи утворюють виражену періодичну структуру, наприклад abababab....

До виконання обчислень сформулюйте прогноз:

1. чи повинні суттєво відрізнятися значення H1 для послідовностей Г і Д;

2. чи повинні суттєво відрізнятися значення H2;

3. для якої послідовності ви очікуєте менше значення H2.

4. чи відрізнятимуться H2 обчислене для біграм що перетинаються і що не перетинаються

Обчисліть H1 та H2 для обох послідовностей.

Порівняйте результати з прогнозом та поясніть:

● чому тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення H1;

● чому їхні значення H2 можуть відрізнятися;

● яку інформацію про джерело дозволяє врахувати модель біграм порівняно з моделлю незалежних символів.

Припущення:

1.H1 будуть ідентичні, адже в двох варіантах беруться один і той же набір символів, просто в одному він зарандомлений, а в іншому ні.

2. Отримані H2 в двох послідовностях мають відрізнятися, адже вони мають показати порядок символів, їх закономірність.

3. Менше H2 очікуємо для Д, адже в цьому випадку кожна біграма детерміновано випливає з попереднього символу - невизначеність пари

мінімальна. Натомість Г після будь-якого символу може стояти будь-який інший.

4. Для Г значення H2, обчислені двома способами, будуть близькі. Для Д значення можуть відрізнятися суттєво: неперетинна нарізка (step=2) при парному періоді структури вибирає біграми лише з кожної другої позиції циклу, тобто бачить підмножину пар символів(17 пар), а не весь їх набір(34 пари, які бачить перетинний варіант).

Пояснення коду програми task3.py

Суть програми - побудова двох послідовностей з гарантовано ідентичними частотами символів. Спочатку з нормалізованого тексту витягується фактичний алфавіт (set, 34 символи, відсортований), з якого формується послідовність Д: рядок "".join(alphabet) повторюється LENGTH/34 разів, що дає періодичну структуру з періодом 34 і рівно 1000 входжень кожного символу. Послідовність Г отримується перестановкою Д через random.shuffle. Оскільки це та сама множина символів, частоти Г і Д збігаються, різниться лише порядок.

Далі обидві послідовності передаються в report, який повністю перевикористовує функції з task2: char_frequencies, bigram_frequencies, h1, h2 - і друкує потрібні результати для порівняння.

Демонстрація роботи програми

PS C:\Users\user\Desktop\Cryptography\Lab1> python -u "c:\Users\user\Desktop\Cryptography\Lab1\task4.py"

G random order:
  H1 = 5.0875
  H2 overlapping = 5.0764
  H2 non-overlapping = 5.0654
  distinct chars = 34
D periodic:
  H1 = 5.0875
  H2 overlapping = 2.5437
  H2 non-overlapping = 2.0437
  distinct chars = 34

Аналіз отриманих результатів:

Логічно, що H1 збіглись, бо набори символів однакові, відповідні й частоти.

Натомість H2 суттєво відрізняються між двома послідовностями Г і Д: для Д наступний символ однозначно визначається попереднім, і модель біграм знижує ентропію приблизно вдвічі (2.5 проти 5), тоді як для Г знання попереднього символу майже нічого не дає.

Також, як і очікувалось, H2 суттєво відрізняються всередині самого Д: пояснюється тим, що при парному періоді нарізка зі зсувом 2 охоплює лише половину переходів циклу (17 з 34 біграм: «аб», «вг» і так далі до «юя»), а перетинний охоплює їх всі (34: «аб», «бв», і так далі до «юя»). Натомість для Г різниця способів несуттєва, як і при тестуванні в другому завданні лаби.

5. Експериментальна оцінка ентропії джерела

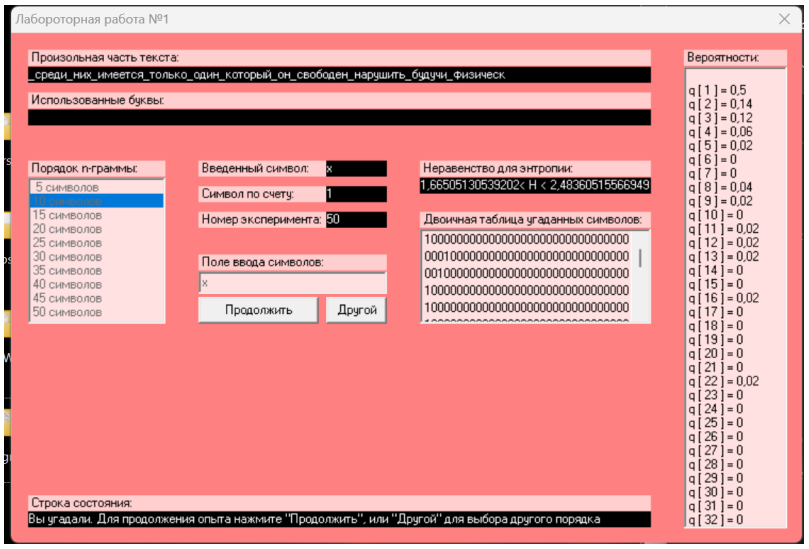
За допомогою програми CoolPinkProgram оцініть значення $H^{(10)}$, $H^{(20)}$, $H^{(30)}$. Для оцінювання кожного значення виконайте не менше 50 експериментів. Порівняйте отримані значення з H1 та H2, обчисленими власною програмою. Результати подайте в одній порівняльній таблиці.

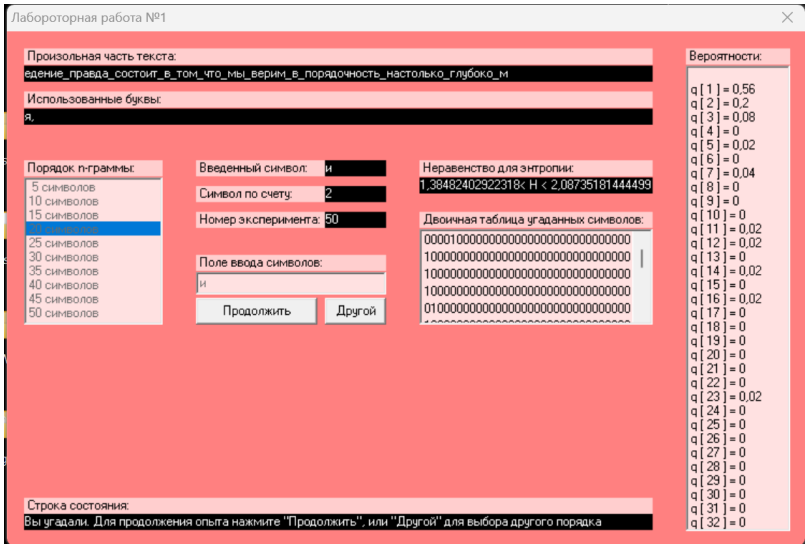
Проаналізуйте отримані результати та поясніть:

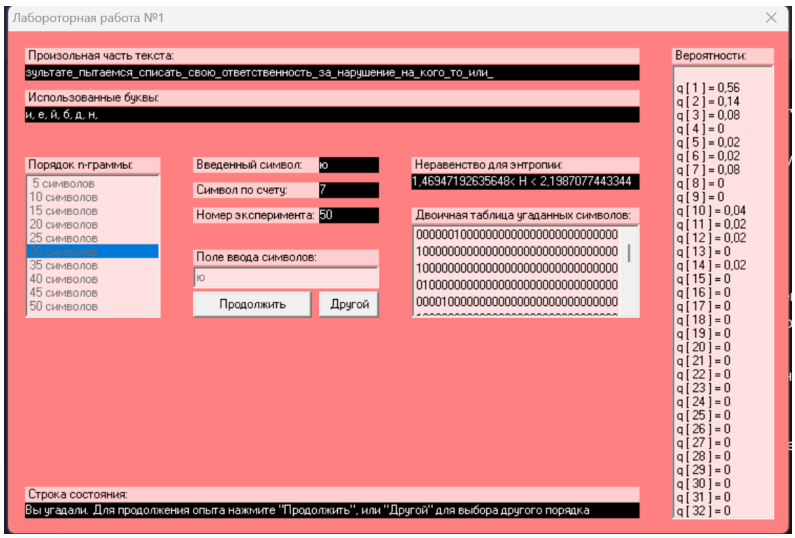
1. чому наведені оцінки ентропії не повинні обов'язково збігатися;
2. які статистичні залежності враховуються при визначенні H1 та H2;
3. чому врахування довших залежностей між символами може змінювати оцінку ентропії природної мови;
4. яку тенденцію можна спостерігати при переході від H1 до оцінок, що враховують дедалі довший контекст.

Перекодували даний текст на Windows 1251 (Cyrillic)

Провели експерименти, вгадуючи наступний символ, отримали дані







Отримані інтервали звели в таблицю, взявши середнє значення для оцінки.

Оцінка	Отримане значення H
H1	4.3778
H2	3.9677
H10	2.0743
H20	1.7359
H30	1.8341

1- Наведені ентропії не збігаються, бо кожна наступна оцінка враховує довший контекст, а врахування додаткових залежностей може лише зменшувати невизначеність.

2- При визначення H1 ніяких залежностей не враховується: кожен символ розглядається як незалежний, і ентропія обчислюється лише з розподілу частот окремих букв. У випадку H2 враховується попередній символ для передбачення поточного.

3- Враховуючи довші залежності, ми починаємо розуміти закономірності мови: наприклад по цій причині відразу зрозуміло яку букву можна поставити в прикладі: «и_физическ» - «и», без контексту перебір дав би багато спроб. І таких прикладів можна навести безліч.

4- При збільшенні контексту, бачимо явне зменшення H. Пояснюється тим, що знаючи закономірності мови ми вже не так часто вдаємося до перебору, а дивимось на попередні літери і на основі цього вже пробуємо вгадувати. Окремо варто зазначити, що в експерименті вийшло H30>H20. Тут варто розуміти: 1-різниця між ними мінімальна, 2-було виконано всього 50 експериментів, тому таке відхилення від номінального результату вважаємо допустимим. 3-ми при проходженні не охоплює всі закономірності мови.

6. Оцінювання надлишковості джерела

Використовуючи отримані значення ентропії, оцініть надлишковість російського письмового тексту для досліджених моделей джерела.

Порівняйте отримані оцінки та поясніть:

● як змінюється оцінка надлишковості при врахуванні залежностей між символами;

● чому природна мова має ненульову надлишковість;

● який зв’язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела.

Для обрахунку значень додали новий стовпець з порахованим надлишковості:

Оцінка	Отримане значення H	R=1-Hx/H0
H0	5,0875	0,0000
H1	4,3778	0,1395
H2	3,9677	0,2201
H10	2,0743	0,5923
H20	1,7359	0,6588
H30	1,8341	0,6395

1- оцінка надлишковості зростає від 14% у моделі незалежних символів, до 22% для біграм, і до 64% у випадках контексту 10-30 символів. Кожен рівень моделі, що враховує більше залежностей, знижує оцінку ентропії, а надлишковість обернено залежить від ентропії - тому вона зростає.

2- природна мова має ненульову надлишковість тому, що в ній букви мають нерівні частоти, з'єднання букв обмежені (далеко не кожна послідовність символів дає слово), слова будуються за граматичними і смисловими правилами. Все це - залежності, які знижують ентропію нижче H0

3- як ми побачили по ходу лаби: чим більша передбачуваність наступного символу, тим менше ентропія(=невизначеність наступного символу), тим більша надлишковість мови

Аналіз результатів

За результатами виконаних експериментів дайте обґрунтовані відповіді на питання. Відповіді повинні містити посилання на результати власних експериментів. Самого наведення теоретичного визначення без інтерпретації отриманих результатів недостатньо.

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Випадкова рівномірна послідовність має максимально рівномірний розподіл, тому її ентропія максимальна: log2(34)=5.087 (у завданні 3 послідовність С дала H1 = 5.0873). Природний текст має нерівномірні частоти букв ("о" - 9.5%, а нечасті букви - частки відсотка) та залежності між сусідніми буквами, і кожна така закономірність знижує невизначеність: H1 тексту з пробілами = 4.378, тобто на 0.71 біт/символ менше максимуму.

2. Яку інформацію про джерело враховує H2, але не враховує H1?

H2 враховує залежності між сусідніми символами, тоді як H1 бачить лише частоти окремих букв, вважаючи їх незалежними. На практиці перехід від H1 до H2 знизив оцінку з 4.378 до 3.968 біт/символ - ці 0.41 біт/символ є інформацією саме про парні залежності.

3. Чи можуть два тексти мати однакове H1, але різне H2? Наведіть приклад із виконаних експериментів.

Так, прямий приклад це завдання 4: послідовності Г і Д побудовані з одного набору символів, тому їхні частоти і H1 абсолютно ідентичні, =5.0875, але H2 різняться більш ніж удвічі: 5.0764 у Г проти 2.5437 у Д. Причина - однаковий склад символів при протилежній структурі порядку, яку фіксує саме біграмна модель.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

H1 зросла з 4.3778 до 4.4668, H2 - з 3.9677 до 4.1474. Пробіл - найчастіший символ тексту (16.4%), його вилучення перерахувало частоти решти букв вгору і вирівняло розподіл, зменшивши перекіс, що і підняло

ентропію. Це показує, що пробіл є повноцінним носієм структури мови який позначає межі слів, і не є просто порожнім символом.

5. Чому оцінки H2, отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Обидва способи оцінюють той самий розподіл біграм, тому різниця мала (3.9677 проти 3.9671), але не нульова: неперетинна нарізка (step=2) дає вдвічі менше спостережень (N/2 проти N−1), отже більший вплив статистичного шуму, а для регулярних структур - систематично іншу підмножину переходів (у завданні 4 для Д: 2.0437 проти 2.5437, бо при парному періоді крок 2 бачить лише половину біграм). Більше статистичних даних використовує спосіб біграм, що перетинаються, і її результати точніші.

6. Чому значення H1, H2, $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Кожна наступна оцінка враховує довший контекст: H1 - тільки частоти букв, H2 - один попередній символ, H10,20,30 - відповідно 9, 19 і 29 попередніх. Врахування додаткових залежностей може лише зменшувати невизначеність, тому оцінки монотонно спадають: 4.378 > 3.9677 > 2.0743 > 1.7359 ≈ 1.8341. Незначне зростання H30 відносно H20 - статистичний шум вибірки з 50 експериментів.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Експеримент із завдання 4 (послідовності Г і Д): він ізольовано показує саме залежності, бо усуває вплив частот - два тексти з абсолютно однаковим розподілом символів дають H2 = 5.0764 (без залежностей) проти 2.5437 (строга залежність "наступний символ визначений попереднім"). Якби залежностей не існувало, обидва значення збіглися б з H1 = 5.0875.

8. Як отримані результати пов’язані з можливістю стиснення природного тексту без втрати інформації?

Надлишковість R, обчислена за нашими оцінками, зростає від 0.14 до 0.64 - тобто з урахуванням довгих залежностей використовується лише 1-0.64=0.36=36% алфавіту і текст теоретично стискається приблизно у

1/0.36=2.8 раза. Це узгоджується з реальною поведінкою архіваторів на текстах і показує, що ентропійні оцінки безпосередньо визначають межу стиснення без втрат: щільніше за H біт/символ закодувати джерело неможливо.

Висновки

У ході роботи ми навчилися експериментально оцінювати ентропію джерела відкритого тексту на символ за різними моделями: за частотами окремих символів, біграм та методом вгадування з довгим контекстом, а також обчислювати надлишковість джерела. Експерименти показали, що врахування залежностей між символами послідовно знижує оцінку ентропії і що природна мова має значну надлишковість (≈0.64), що пояснює можливість стиснення тексту без втрати інформації.